

[项目名称] 模拟患者大语言模型构建计划

1. 项目概述

- 目标：**在医患问答环境下，已知患者病症作为上下文，需要在医生问诊文本输入时，实现模拟患者情绪，感受，认知等语言特点。

2. 基座模型选择

- 要点：**模型大小，应答速度，适应硬件算力、存储

3. 数据准备

3.1 数据来源

- 问诊平台爬取，与医院协作收集，或寻找公开数据集

3.2 数据清洗

3.3 数据格式与预处理

4. 微调配置

4.1 微调方法

- ☐ 全参数微调
- ☐ LoRA
- ☐ QLoRA

4.2 训练框架与工具

- 框架：HuggingFace Transformers + PEFT / Axolotl / 其他
- ☐ / FSDP / 单卡

4.3 硬件资源

- GPU 型号与数量：
- 显存需求预估：
- CPU 与内存：

5. 训练超参数

参数	设定值	说明
per_device_batch_size	[]	
gradient_accumulation_steps	[]	
learning_rate	[]	优化器类型：AdamW

不太理解的部分： ☐ | ☐ || ☐ ||| save_strategy | epoch / steps ||| fp16 / bf16 | True / False ||

6. 训练模型参数

7. 评估与验证

7.1 自动评估

- 困惑度
- 数据集准确率
- 任务特定指标：BLEU / ROUGE / 准确率 / F1

7.2 人工评估

- 抽样数量：
- 评估维度：相关性、流畅性、准确性

8. 部署

9. 风险与应对

- **风险1**：[例如过拟合]
- 应对：增加正则化、数据增强
- **风险2**：[显存不足]
- 应对：使用梯度累积、QLoRA